

Optimisation des Hyperparamètres pour la Classification des Logiciels Malveillants

Membres du groupe:

Aboubakar SALY

Mama NDIAYE

1. Méthodologie

Dans le cadre de cette étude, une sélection rigoureuse d'algorithmes de classification a été effectuée, fondée sur leur réputation d'efficacité et leur popularité dans la communauté du machine learning. Cette sélection comprend le Decision Tree Classifier (DTC), Random Forest, K-Nearest Neighbors (KNN) et LightGBM. Ces algorithmes ont été choisis pour leur diversité en termes d'approches de classification, allant des méthodes basées sur des arbres à des techniques d'ensemble, offrant ainsi un large spectre d'analyse sur les performances de classification dans le contexte spécifique de la détection des logiciels malveillants.

Pour chaque algorithme, nous avons entrepris une identification minutieuse des trois hyperparamètres ayant le plus d'impact sur la performance de classification. Cette identification s'est appuyée sur une combinaison de recherches bibliographiques et d'expérimentations préliminaires, afin de garantir que notre optimisation ciblait les aspects les plus cruciaux de chaque modèle.

Afin de déterminer les meilleures combinaisons de valeurs pour ces hyperparamètres, nous avons mis en œuvre des méthodes d'optimisation avancées, notamment le Grid Search. Ces techniques nous ont permis d'explorer systématiquement et de manière exhaustive l'espace des hyperparamètres, en vue de maximiser la précision de classification de chaque algorithme. Cette approche méthodique assure que les configurations optimales sont identifiées avec une grande confiance, tout en soulignant les différences intrinsèques dans la sensibilité des algorithmes aux ajustements de leurs hyperparamètres.

2. Résultats

Ce tableau compare les performances de différents algorithmes de classification utilisés pour la classification des logiciels malveillants, avant et après l'optimisation des hyperparamètres. Les résultats incluent la précision, le score F1, le temps d'entraînement et la matrice de confusion pour chaque algorithme. Enfin, une recommandation sur le meilleur algorithme et ses hyperparamètres est fournie, basée sur ces critères.

Algorithme	Précision (Avant)	Précision (Après)	Score F1 (Après)	Meilleurs Hyperparamètres	Temps d'Entraînement (s)	Matrice de Confusion (Après)
Decision Tree	0.9882	0.9876	0.9795	{'max_depth': 20, 'min_samples_leaf': 1, 'min_samples_split': 2}	19.5510	[[23804, 224], [201, 10132]]
Random Forest	0.9918	0.9914	0.9857	{'max_depth': 20, 'min_samples_split': 2, 'n_estimators': 100}	193.9463	[[23870, 158], [137, 10196]]
KNN	0.9705	0.9763	0.9608	{'metric': 'manhattan', 'n_neighbors': 7, 'weights': 'distance'}	96.5540	[[23557, 471], [344, 9989]]
LightGBM	0.9868	0.9906	0.9844	{'num_leaves': 31, 'learning_rate': 0.05, 'n_estimators': 100}	156.5611	[[23845, 183], [141, 10192]]

La Figure suivante présente les performances avant et après optimisation pour chaque algorithme, ainsi que les meilleurs hyperparamètres identifiés.




Figure 1: Comparaison de la Précision Avant et Après Optimisation

3. Discussion

L'optimisation des hyperparamètres a, dans plusieurs cas, conduit à une amélioration des performances des algorithmes de classification. Cependant, il est crucial de reconnaître que l'augmentation de la précision n'est pas systématique et que l'efficacité du processus d'optimisation peut varier significativement d'un algorithme à l'autre. De manière plus nuancée, nous observons que, pour certains modèles, l'amélioration marginale de la précision peut ne pas justifier le temps d'entraînement nettement plus long. Il est donc impératif d'adopter une approche équilibrée, prenant en compte à la fois la précision accrue et le coût en termes de temps et de ressources computationnelles. Cette démarche met en lumière l'importance de sélectionner judicieusement non seulement les algorithmes mais aussi les hyperparamètres, en visant un compromis optimal entre précision et efficacité opérationnelle.

4. Conclusions et Recommendations

Cette étude met en exergue le rôle crucial de l'optimisation des hyperparamètres dans la quête de performances améliorées pour les modèles de classification, particulièrement dans le contexte de la classification des logiciels malveillants. Néanmoins, il est devenu évident que l'optimisation ne garantit pas systématiquement les améliorations attendues et peut, dans certains cas, entraîner une augmentation disproportionnée du temps d'entraînement. En considérant l'équilibre entre la précision, le score F1 et l'efficacité, le modèle LightGBM optimisé se distingue comme étant particulièrement performant. Il offre une précision et un score F1 élevés, tout en maintenant un temps d'entraînement raisonnable, ce qui le positionne comme un choix privilégié pour la classification efficace des logiciels malveillants. Nous recommandons donc son utilisation dans des contextes similaires, tout en soulignant l'importance d'une évaluation approfondie des compromis entre l'amélioration de la précision et le coût computationnel associé à l'optimisation des hyperparamètres.